신 호 영

Hoyoung Shin

AI Engineer.

기술 핵심 키워드

LLM · RAG · LoRA

Embedding · Reranker

vLLM · AI Agent · STT

Python · PyTorch · TensorFlow

경력사항

총 경력 **6년 9개월**

2022.08 — 현재 (4년 2개월)

우리은행 AI데이터사업부 · 대리

대출·청약·예적금 상담과 기업용 챗봇 등 **금융권 생성형 AI 서비스**의 설계와 모델 개발, 운영 고도화를 담당합니다. 현업 요구사항을 서비스 흐름으로 구체화하고, 학습 데이터 구축부터 모델 튜닝·검색·서빙까지 연결합니다.

LLM 튜닝·서빙 한국어·금융 도메인·업무 수행 데이터를 구성하고, 질의 최적화와 답변 생성 목적에 맞춰 학습 데이터를 증강했습니다. 역할별 **LoRA** 어댑터를 튜닝하고 **vLLM** 기반 서빙, 스트리밍 응답, 세션 상태를 고려해 서비스 흐름에 연결했습니다.

RAG·멀티턴 상담 대출 상품 정보와 입주자모집공고 등 금융 문서의 수집·전처리·청크 분할 및 벡터 DB 반영 흐름을 구성했습니다. 의도 분류와 정보 추출, **Embedding·Reranker** 검색을 답변 생성에 연결하고, 상품 선택 상태·사용자 권한·대화 맥락을 반영한 멀티턴 상담을 설계했습니다.

AI Agent·사업 운영 고객상담 영역의 AX 사업 관리를 담당하며, 상담 직원의 정보 탐색과 업무 지원을 위한 **KMS·STT 고도화** 및 학습·서빙 관련 Agent 파이프라인을 설계했습니다. 상담 데이터와 업무 지식의 활용 흐름을 정리하고 서비스 적용 방향을 검토했습니다.

데이터 구축·검증 예적금 상담·가입 시나리오와 대화 상태·업무 정책을 정의하고, 모델 간 대화 생성 및 크라우드워커 기반 대화형 데이터셋 제작 사업을 운영했습니다. PoC 분석과 모델 검증을 수행하고, 디지털 휴먼·영상합성 플랫폼의 구축 사업 관리와 운영 실무를 담당했습니다.

2019.10 — 2022.05 (2년 7개월)

(주)골든플래닛 데이터분석부 · 파트장

기업과 공공기관을 대상으로 **AI·데이터 분석 컨설팅**을 수행했습니다. 비즈니스 요구사항에 맞춰 분석 방법론을 수립하고, 데이터 수집·가공부터 모델 개발·성능 검증·인사이트 리포팅까지 전 과정을 담당했습니다.

자연어 처리·분류 제품·경쟁사 키워드로 수집한 소셜데이터를 바탕으로 **KoBERT** 기반 감성 분류와 속성 멀티라벨 분류 모델을 개발했습니다. 광고 이미지의 **OCR** 텍스트 추출과 **FastText·Bi-LSTM** 기반 단어 분류를 수행하고, 위험 표현 분석 및 대체어 추천으로 사전 검토를 지원했습니다.

예측 모델링·검증 은행·카드 기업의 3개 앱에서 수집한 **GA 행동 데이터**를 통합하고 페이지별 행동 패턴에서 예측 변수를 추출했습니다. 대출 신청·이탈 예측 PoC에서 **XGBoost** 등 모델의 성능을 비교했으며, 테스트 데이터의 일반화 한계를 검토하고 과적합 대응과 GA 수집기 개선을 진행했습니다.

통계 분석·컨설팅 약 200개 공공기관 SNS 계정의 채널별 특성과 운영 현황을 통계적으로 분석하고, 채널 간 비교가 가능한 종합 **KPI**를 개발했습니다. 소셜데이터 분류 결과와 계정별 분석을 인사이트·제언 보고서로 정리해 마케팅 의사결정과 디지털 자산의 유지·폐쇄 판단을 지원했습니다.

프로젝트

우리은행

AI 대출상담원

대출 상품과 일반 금융 지식을 구분해 상담하는 대고객 AI 서비스.

담당
서비스 구조 설계 · 전용 모델 학습 · 고도화

기술 / 방법
LLM · RAG · Intent Classification · Multi-turn

배경과 과제

대출 상담은 고객이 특정 상품을 선택했는지, 자금의 용도와 담보가 무엇인지에 따라 필요한 정보가 달라집니다. 상품 설명과 일반 대출 지식을 같은 흐름으로 처리하면 질문에 적합한 답변 범위를 정하기 어렵기 때문에, 고객의 의도와 상담 상태를 구분하는 구조가 필요했습니다. 금융 업무의 제약을 고려하면서도 여러 차례 이어지는 질문에 대응하는 것이 주요 과제였습니다.

구현 구조

의도와 상담 상태 파악

고객 질문에서 상품 질문·일반 질문 등을 구분하고 용도와 담보 정보를 추출합니다. 상품 선택 상태를 함께 확인해 현재 고객이 어떤 상담 단계에 있는지 판단하는 흐름으로 구성했습니다.

상품 지식과 일반 지식 검색

상품이 선택된 경우에는 해당 상품 정보와 질문을 함께 사용해 질의를 정제하고 상품 문서를 검색합니다. 상품을 정하지 않은 경우에는 용도·담보 정보를 활용하거나 일반 대출 지식을 검색하도록 분기했습니다.

답변 생성과 대화 연결

검색된 상품 데이터 또는 일반 문서 데이터를 바탕으로 답변을 생성합니다. 멀티턴과 대화 이어가기 기능을 확장하면서 이전 대화의 정보와 상품 선택 상태가 후속 질문에 연결되도록 고도화했습니다.

담당 업무

서비스 설계와 전용 모델 학습

첫 출시 단계부터 서비스 전반의 구조와 전용 모델 학습을 담당했습니다. 질문 의도, 용도·담보 정보, 상품 선택 여부를 서비스 분기 조건으로 구체화하고 분류 결과가 검색·답변 단계에 반영되도록 설계했습니다.

질의 정제와 검색 흐름 개선

상품 관련 질문과 일반 질문의 검색 대상을 분리했습니다. 선택한 상품 정보와 고객 질문을 함께 활용하는 Query Refinement를 적용해 상담 맥락에 맞는 정보를 찾도록 파이프라인을 구성했습니다.

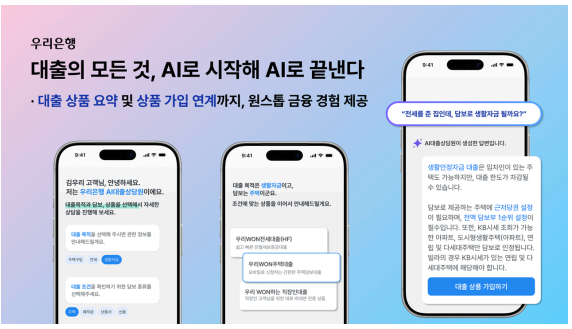
출시 이후 기능 확장

출시 이후에도 대출 상품 범위 확대와 멀티턴, 대화 이어가기 기능의 고도화를 담당했습니다. 금융 상담에서 안내할 수 있는 답변 범위와 고객의 정보 탐색 요구를 함께 고려하며 모델과 서비스 흐름을 개선했습니다.

결과와 기여

단일 상품 지식을 조회하는 방식에서 고객의 의도·용도·담보·상품 선택 상태를 반영하는 상담 구조로 확장했습니다. 서비스 설계와 모델 학습을 함께 담당하며, 출시 이후 기능과 상품 범위가 늘어나는 과정에서도 검색·대화 파이프라인을 지속적으로 고도화했습니다.

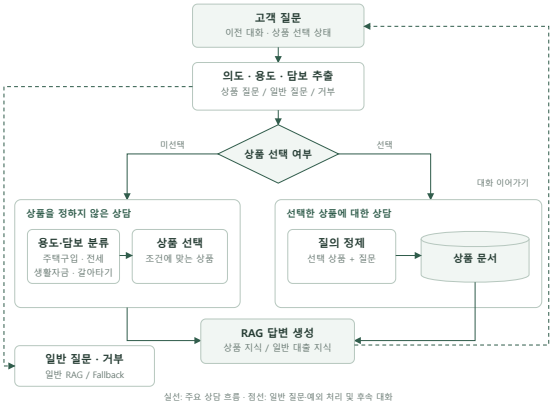
AI대출상담원 공개 화면



대출 목적·담보 선택에서 상품 안내와 후속 질문으로 이어지는 상담 화면입니다.

우리은행 제공 · 베타뉴스, 2025.12.26 ↗

상태 기반 상담 분기



상품을 선택하기 전과 후의 처리 경로를 나누고, 질문 의도에 따라 상품·일반 지식 또는 Fallback으로 연결합니다.

프로젝트

우리은행

AI 청약상담원

최신 입주자모집공고를 검색해 청약 관련 질문에 답하는 상담 서비스.

담당	기술 / 방법
사업 관리 · 검색 파이프라인 설계 · 모델 관리 및 검증	RAG · Embedding · Vector DB · LLM

배경과 과제

청약 상담은 긴 입주자모집공고 안에서 지역, 모집공고명, 순위와 같은 조건에 맞는 내용을 찾아야 합니다. 공고마다 신청 자격과 세부 조건이 다르고 새로운 문서가 계속 추가되므로, 문서 최신화와 질문 조건을 반영한 검색을 함께 설계해야 했습니다. 검색한 근거를 대화형 답변으로 연결하는 RAG 서비스가 개발의 중심이었습니다.

구현 구조

최신 공고 수집과 문서 갱신

매일 최신 입주자모집공고를 수집하고 공고 형식에 맞춘 전처리를 수행합니다. 전처리한 문서를 청크 단위로 나눠 Vector DB에 업데이트하여 새 공고가 검색에 반영되는 흐름을 구성했습니다.

질문 조건 추출과 검색

질문에서 의도와 공고명·지역·순위 등의 엔티티를 추출합니다. 사용자의 질문을 조건 정보와 함께 검색 단계로 전달하고, 관련 문서에서 상담에 필요한 문맥을 찾도록 연결했습니다.

문맥 기반 답변 생성

질문, 의도, 엔티티, 검색 Context를 프롬프트에 결합해 LLM 답변 생성에 활용합니다. 공고문을 근거로 이어지는 질문에 대응할 수 있도록 멀티턴 상담 파이프라인을 설계했습니다.

담당 업무

사업 관리와 검색 모델 개발

생성형 AI 플랫폼 사업의 청약 상담 서비스 구축 과정에서 사업 관리와 검색 모델 개발을 담당했습니다. 문서 갱신과 질문 조건별 검색이 하나의 서비스 흐름으로 동작하도록 파이프라인을 설계했습니다.

문서 전처리와 RAG 구성

공고문을 검색에 활용할 수 있는 형태로 전처리하고 청크 단위 업데이트를 구성했습니다. 공고명과 지역 등 질문의 주요 정보를 검색 과정에 반영하고, 검색 결과를 답변 생성 단계와 연결했습니다.

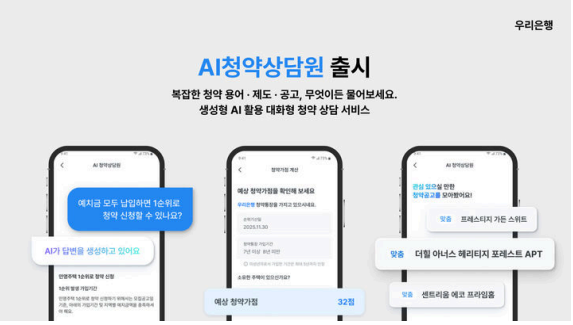
모델 학습 관리와 운영 검증

RAG 기반 파이프라인의 모델 학습 관리와 검증을 수행했습니다. 출시 이후에도 검색 모델과 생성 모델을 지속적으로 관리하며 공고문 기반 질의응답 서비스를 고도화했습니다.

결과와 기여

최신 입주자모집공고를 수집·갱신하는 데이터 흐름과, 질문 조건에 맞춰 근거 문서를 검색하는 상담 흐름을 함께 구축했습니다. 문서 검색에서 답변 생성까지의 연결뿐 아니라 출시 이후 모델 관리와 검증 업무도 수행했습니다.

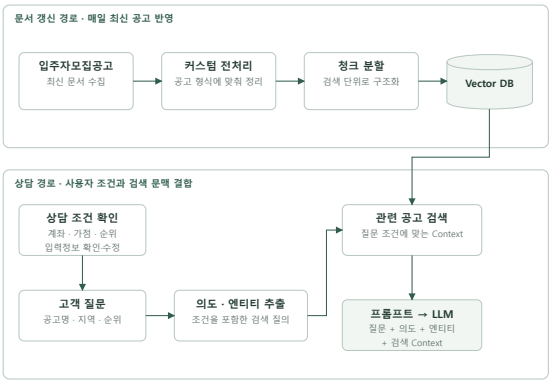
AI청약상담원 공개 화면



청약 질의응답과 가점·순위 계산, 공고 안내를 보여주는 서비스 공개 이미지입니다.

우리은행 제공 · 뉴시스, 2025.11.24 ↗

공고문 갱신과 상담 파이프라인



문서의 최신화와 사용자별 상담 조건을 별도 경로로 관리

상단은 문서 수집·갱신, 하단은 상담 조건 확인부터 검색 근거를 포함한 답변 생성까지의 흐름입니다.

프로젝트

우리은행

원비즈플라자 챗봇

기업용 구매·공급 플랫폼의 메뉴와 사용 방법을 안내하는 LLM 챗봇.

담당
서비스 모델 설계 · 학습 데이터 구축 · 모델 튜닝

기술 / 방법
LoRA · Embedding · Reranker · vLLM

배경과 과제

원비즈플라자는 기업의 구매·공급 업무를 처리하는 플랫폼으로 메뉴가 많고 사용자 권한에 따라 안내 범위가 달라집니다. 같은 질문도 현재 화면과 이전 대화에 따라 의미가 달라질 수 있어, 단순한 FAQ 검색을 넘어 화면 맥락과 권한을 고려한 안내가 필요했습니다. 사용자 편의성과 관리자의 안내 업무 부담을 함께 고려한 챗봇 구축을 진행했습니다.

구현 구조

질문 분리와 최적화

현재 화면 정보와 대화 맥락을 바탕으로 질문을 분리·최적화합니다. 해당 역할을 담당하는 LoRA 어댑터를 별도로 학습해 검색에 적합한 질의로 연결했습니다.

플랫폼 문서 검색

Embedding 검색과 Reranker를 활용해 관련 문서를 찾는 파이프라인을 구성했습니다. 대량의 메뉴와 사용자 권한을 고려해 검색 흐름을 커스터마이징하고 화면에 맞는 상대적인 안내를 지원했습니다.

답변 생성과 스트리밍

답변 생성용 LoRA 어댑터에 검색 결과를 전달하고 vLLM 서빙을 통해 응답을 생성합니다. SSE 기반 스트림 처리와 세션 유효 시간, 오류·Timeout 응답을 고려한 서비스 연결 구조를 설계했습니다.

담당 업무

서비스 모델 설계와 제작

챗봇의 서비스 모델 설계와 제작을 담당했습니다. 질문 처리, 문서 검색, 답변 생성의 역할을 나누고 프런트엔드·백엔드와 서빙 API 사이의 응답 흐름을 구성했습니다.

역할별 데이터 증강과 LoRA 튜닝

질문 분리·최적화와 답변 생성을 서로 다른 두 LoRA 어댑터로 분리했습니다. 각 역할에 맞춰 학습 데이터를 증강하고 튜닝했으며, 현재 화면 정보를 활용하는 안내를 위해 모델 학습 데이터를 구축했습니다.

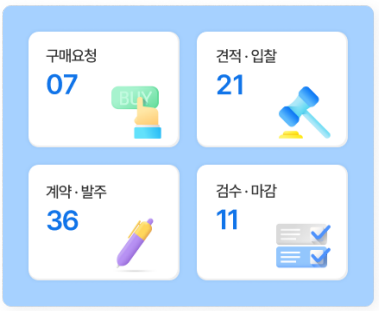
검색과 모델 서빙 연계

Embedding·Reranker 기반 검색을 답변 생성과 연결하고 vLLM 기반 서빙으로 구성했습니다. 멀티턴 상담과 권한별 정보 안내, 스트리밍 응답을 함께 고려해 플랫폼 사용 흐름에 맞는 구조를 구현했습니다.

결과와 기여

질의 최적화와 답변 생성의 역할을 분리하고, 문서 검색과 모델 서빙을 연결한 기업용 플랫폼 챗봇을 구축했습니다. 모델 튜닝뿐 아니라 화면 맥락, 권한, 세션과 응답 처리까지 고려하며 실제 서비스 사용 흐름에 맞춰 설계했습니다.

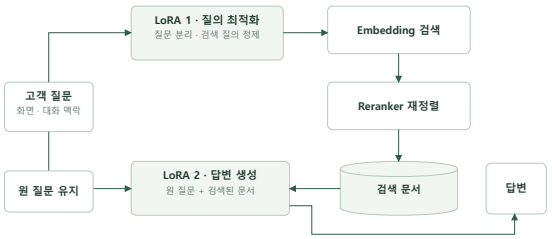
챗봇이 안내하는 기업용 플랫폼



원비즈플라자 공식 소개의 통합 대시보드입니다. 챗봇은 플랫폼의 메뉴·사용 방법을 안내합니다.

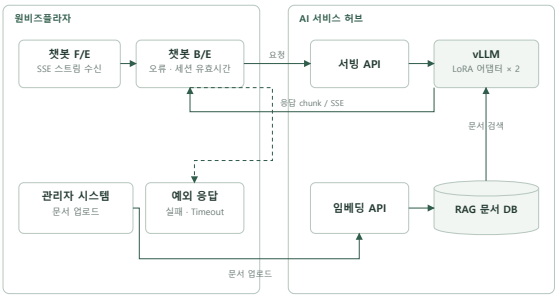
원비즈플라자 공식 홈페이지 · 플랫폼 소개 화면 ↗

질의 최적화와 답변 생성의 분리



질의를 정제한 검색 경로와 원 질문을 유지하는 경로가 답변 생성 단계에서 합쳐집니다.

서비스 운영·서빙 연결



사용자 요청과 관리자 문서 업로드를 분리하고, 스트리밍 응답·세션·오류 처리를 함께 표현했습니다.

프로젝트

우리은행

고객상담 AI Agent

고객센터 직원의 상담을 지원하기 위한 지식 검색과 STT 고도화 프로젝트.

담당	기술 / 방법
고객상담 영역 사업 관리 · Agent 파이프라인 설계	AI Agent · STT · KMS · Python

배경과 과제

고객센터 직원은 상담 중 고객의 질문을 이해하고 업무 지식에서 필요한 정보를 빠르게 찾아야 합니다. 정확한 안내와 응대 시간 단축을 목표로 상담 데이터와 지식 기반을 연결할 필요가 있었으며, 새로운 KMS 구축과 STT 고도화가 함께 진행됐습니다. 고객상담 업무에 AI Agent를 적용하기 위한 데이터·학습·서빙 흐름의 설계가 주요 범위였습니다.

구현 구조

상담 업무와 정보 활용 흐름 정리

고객센터 직원을 사용자로 설정하고 상담 과정에서 필요한 정보 탐색과 지원 업무를 정리했습니다. 고객 상담 데이터와 업무 지식이 활용되는 지점을 중심으로 서비스 요구사항을 구체화했습니다.

STT와 KMS 기반 구성

음성 상담 데이터를 활용하기 위한 STT 고도화와 새로운 KMS 구축을 진행했습니다. 상담 기록과 지식 검색을 상담 보조 업무에 연결할 수 있도록 데이터 수집·활용 흐름을 설계했습니다.

학습·서빙 Agent 파이프라인

고객센터에서 사용할 STT 학습·서빙 관련 Agent 파이프라인을 설계했습니다. 개별 모델의 개발뿐 아니라 상담 업무에서 데이터와 모델이 이어지는 전체 흐름을 검토했습니다.

담당 업무

고객상담 영역 AX 사업 관리

다양한 업무 효율화를 위한 AX 사업 중 고객상담 영역의 사업 관리를 담당했습니다. 고객센터 직원의 상담 지원 목적에 맞춰 업무 요구사항과 개발 범위를 정리했습니다.

STT 고도화와 지식 기반 연계

STT 고도화 및 KMS 구축 과정에서 상담 데이터와 업무 지식을 활용하는 구조를 검토했습니다. 상담 중 정보 탐색을 지원한다는 업무 목표에 맞춰 각 구성 요소의 연결 방향을 설계했습니다.

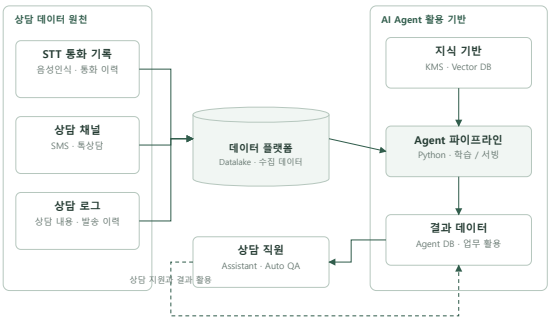
Agent 파이프라인 설계

STT 학습과 서빙에 관련된 Agent 파이프라인 설계를 담당했습니다. 학습 데이터가 모델 활용 단계로 이어지는 과정을 정리하고, 고객상담 업무에 적용할 수 있는 구조로 구체화했습니다.

결과와 기여

고객상담 영역의 AX 사업 관리와 STT 학습·서빙 관련 Agent 파이프라인 설계를 수행했습니다. 상담 직원의 정보 탐색을 지원하기 위해 음성 상담 데이터와 지식 기반을 함께 고려한 서비스 기반을 설계했습니다.

데이터 수집·지식·Agent의 연결



첨부 자료의 상담 채널, 데이터 플랫폼, KMS·Agent 플랫폼을 중심으로 고객상담 영역의 연결 구조를 재구성했습니다.

프로젝트

우리은행

AI 예적금상담원 · AI Banker

예금·적금 상품의 상담과 가입 여정을 대화로 연결하는 AI 서비스.

담당

사업 관리 · 업무 시나리오 설계 · 학습 데이터 제작

기술 / 방법

Fine-tuning · LoRA · NLU · Dialogue State

배경과 과제

예적금 상담은 상품 설명에 답하는 것뿐 아니라 고객 조건을 이해하고 가입 과정까지 이어져야 합니다. 질문의 의도와 상품·우대조건 같은 정보를 별도로 파악하고, 대화 중 수집한 정보를 다음 단계에서 재사용하는 구조가 필요했습니다. 한국어와 금융 도메인에 맞는 모델 학습 데이터, 업무 시나리오와 대화 관리가 함께 요구됐습니다.

구현 구조

언어 이해와 대화 상태 관리

NLU에서 의도 분류와 정보 추출을 수행하고, 발화 정보를 대화 상태에 저장합니다. 추출된 의도와 정보를 답변 생성에서도 재활용해 업무 처리와 대화 맥락을 연결하는 방식으로 설계했습니다.

정책 결정과 업무 처리

대화 상태를 바탕으로 답변 정책과 Task Manager 호출을 결정합니다. 상품 정보 조회, 우대조건 추출, 이자율·만기금액 계산 등 가입 여정에 필요한 업무를 대화 흐름 안에서 연결하는 시나리오를 구성했습니다.

데이터 구성과 모델 적용

한국어 공통 데이터, 금융 업무 데이터, 예적금 가입과 복합대화 등 업무 수행 데이터를 단계적으로 구성했습니다. 대화형 데이터 증강과 크라우드워커 데이터셋 제작을 통해 모델 학습에 사용할 대화 데이터를 마련했습니다.

담당 업무

업무 시나리오와 고객 여정 설계

예금·적금 상품 가입 시나리오를 정의하고 상담에서 가입까지의 여정을 파이프라인으로 설계했습니다. 언어 이해, 상태 관리, 정책 결정, 업무 처리, 답변 생성이 단계별로 연결되도록 구성했습니다.

데이터 증강과 제작 사업 운영

모델 간 대화인 M2M 방식을 활용한 대화형 데이터 증강 알고리즘을 개발했습니다. 크라우드워커 기반 대화형 데이터셋 제작 사업을 운영·관리하고, 한국어와 금융 도메인 및 업무 수행 목적에 맞는 데이터를 제작했습니다.

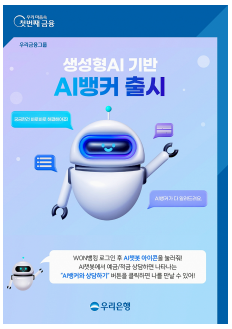
RAG 구성과 PoC 분석

RAG 기반 QA 응답 모델의 파이프라인 설계와 데이터 구현에 참여했습니다. 자체 PoC 분석과 실험을 수행하며 모델의 범용성과 적용 범위를 검토하고 금융 상담 업무에 맞는 활용 방식을 확인했습니다.

결과와 기여

상품 설명 중심의 질의응답과 실제 가입 업무를 대화형 서비스로 연결하는 시나리오를 설계했습니다. 사업 관리, 데이터 제작, 데이터셋 구축 운영과 PoC 분석을 수행하며 금융 도메인 대화 시스템 개발을 경험했습니다.

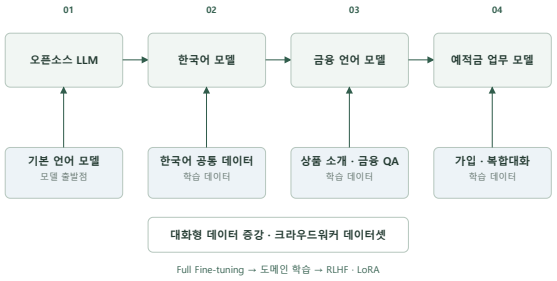
AI뱅커 서비스 공개 이미지



우리WON뱅킹에서 예적금 상담을 제공하는 AI뱅커의 출시 안내 이미지입니다.

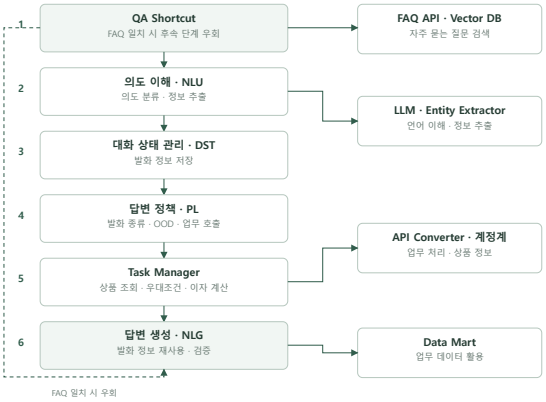
우리은행 제공 · 머니투데이, 2024.04.07 ↗

단계별 학습과 데이터 구성



기본 모델에서 한국어·금융·업무 수행 모델로 확장하고, 단계별 데이터를 적용하는 학습 구조입니다.

업무 수행형 대화 시스템



일반 질의응답과 업무 실행을 구분하며, 추출한 정보와 대화 상태를 이후 단계에서 재사용합니다.

프로젝트

우리은행

영상합성 솔루션 · 디지털 휴먼

영업점과 디지털데스크에서 활용할 디지털 휴먼 및 영상제작 플랫폼.

담당
사업 관리 · 검증 · 운영 실무

기술 / 방법
Digital Human · Video Synthesis

배경과 과제

영업점과 디지털데스크에서 은행을 대표하는 디지털 휴먼을 활용하기 위해 영상합성 솔루션과 영상 제작 플랫폼 구축을 진행했습니다. 인물과 가상 얼굴을 활용한 합성 기술을 실제 서비스 환경에 적용하고, 구축 이후의 운영까지 이어지는 사업이었습니다. 기술 자체뿐 아니라 활용 목적에 맞는 서비스 검증과 운영 관리가 필요한 프로젝트였습니다.

구현 구조

디지털 휴먼 제작

실제 아나운서와 가상 얼굴을 활용해 은행 서비스에 사용할 디지털 휴먼을 제작하는 사업을 진행했습니다. 영업점과 디지털데스크 등 활용 환경을 고려하며 제작·적용 범위를 검토했습니다.

영상합성 플랫폼 구축

디지털 휴먼을 활용한 영상 제작 플랫폼 서비스 구축을 진행했습니다. 영상합성 기술을 서비스에서 사용할 수 있는 형태로 연결하는 사업 관리와 검증 업무를 수행했습니다.

검증과 운영

구축 단계의 검증에 참여하고 영상합성 솔루션의 운영 단계 실무를 담당했습니다. 제작된 디지털 휴먼과 플랫폼이 실제 활용 목적에 맞게 운영되는 과정을 관리했습니다.

담당 업무

구축 사업 관리

디지털 휴먼 제작과 영상합성 플랫폼 구축 사업의 관리 업무를 담당했습니다. 기술 구현의 세부 모델 개발보다는 사업 진행과 서비스 활용 관점에서 구축 과정을 관리했습니다.

기술·서비스 적용 검증

디지털 휴먼 개발 사업의 검증에 참여하고 서비스 목적과 활용 환경에 맞는 적용을 검토했습니다. 영업점과 디지털데스크의 접점에서 영상 제작 플랫폼을 어떻게 활용할지 함께 고려했습니다.

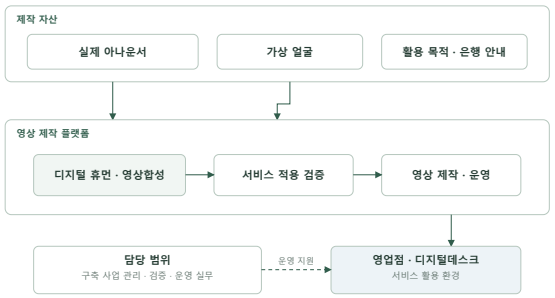
운영 단계 실무

영상합성 솔루션의 운영과 관리 업무를 수행했습니다. 구축 완료 이후에도 서비스 운영에 참여하며 디지털 휴먼과 영상 제작 플랫폼의 활용을 지원했습니다.

결과와 기여

디지털 휴먼과 영상합성 플랫폼 구축 사업의 관리·검증·운영 실무를 수행했습니다. 모델 개발과 다른 관점에서 AI 솔루션의 서비스 도입과 운영 과정을 경험하고, 기술을 현업 환경에 연결하는 업무를 담당했습니다.

제작 자산에서 현장 운영까지



모델 학습 구조 대신, 첨부 자료에 명시된 디지털 휴먼 제작과 영상 플랫폼의 사업 관리·운영 범위를 구분했습니다.

(주)골든플래닛

소셜데이터 자동 분류

전자제품 기업의 소셜데이터를 속성과 감성으로 분류하고 마케팅 인사이트를 도출한 프로젝트.

담당
자연어 분류 모델 개발 · 데이터 분석 · 리포팅

기술 / 방법
KoBERT · Multi-label Classification · NLP

배경과 과제

고객사와 경쟁사 제품에 대한 소셜데이터에는 제품 속성과 긍정·부정 반응이 함께 나타납니다. 한 문장에 여러 속성이 포함될 수 있어 단일 카테고리 분류만으로는 정보를 충분히 정리하기 어려웠습니다. 자연어 데이터를 속성과 감성으로 구조화하고, 분석 결과를 마케팅 의사결정에 활용할 수 있도록 제공하는 것이 목적이었습니다.

구현 구조

제품·경쟁사 키워드 기반 데이터

고객사의 제품과 경쟁사 관련 키워드를 바탕으로 수집한 소셜데이터를 분석 대상으로 삼았습니다. 자유로운 문장에 담긴 제품 반응을 속성과 감성 관점에서 분류할 수 있도록 구성했습니다.

감성·속성 자동 분류

KoBERT 기반 딥러닝 모델을 활용해 제품별 감정 분류와 카테고리 멀티라벨 분류를 수행했습니다. 한 문장에 여러 제품 속성이 포함되는 경우에도 다차원 분류 결과로 구조화했습니다.

분석과 마케팅 리포팅

모델의 분류 Output을 바탕으로 데이터를 분석하고 고객사와 경쟁사 제품에 대한 반응을 정리했습니다. 분석에서 확인한 인사이트를 마케팅 제언과 의사결정 지원 보고서로 연결했습니다.

담당 업무

자연어 분류 모델 개발

KoBERT를 활용한 감정 분류 및 카테고리 멀티라벨 분류 모델을 개발했습니다. 단순한 키워드 집계가 아니라 문장 수준의 자연어 정보를 분류 결과로 전환하는 역할을 수행했습니다.

분류 결과 기반 데이터 분석

자동 분류된 속성과 감성 정보를 후속 분석에 활용했습니다. 고객사 제품과 경쟁사 제품을 분석하고 마케팅 관점에서 활용할 수 있는 주요 반응과 인사이트를 정리했습니다.

인사이트 도출과 제언

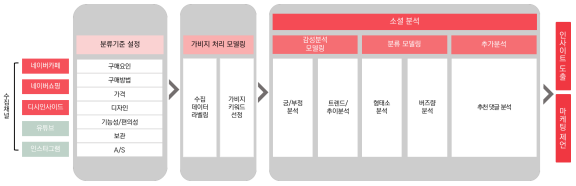
모델 개발에 그치지 않고 분류 결과를 고객사의 의사결정에 활용할 수 있는 리포트로 작성했습니다. 기술적인 분류 결과를 제품·마케팅 관점의 분석과 제언으로 전달했습니다.

결과와 기여

소셜데이터를 제품 속성과 감성으로 자동 분류하고, 그 결과를 마케팅 인사이트와 제언 보고서로 연결했습니다. 자연어 처리 모델의 Output이 실제 비즈니스 분석과 의사결정 자료로 활용되는 전체 과정을 수행했습니다.

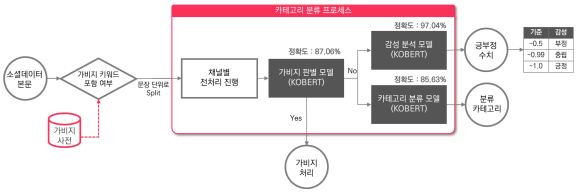
프로젝트 자료

소셜데이터 분석 범위



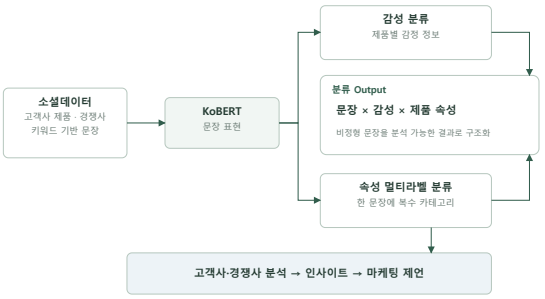
제품·경쟁사 키워드 수집, 분류 기준 설정, 감성·속성 분석과 마케팅 제언으로 이어지는 분석 범위입니다.
기존 포트폴리오 · 8쪽

노이즈 판별과 감성·속성 분류



가비지 키워드와 판별 모델로 분석 대상을 구분한 뒤 감성과 카테고리를 분류하는 원본 구조입니다. 그림의 정확도는 기존 자료에 기재된 당시 실험 결과입니다.
기존 포트폴리오 · 8쪽

감성과 속성을 나누는 다중 출력 구조



감성 분류와 멀티라벨 속성 분류를 별도로 표현하고, 두 결과가 마케팅 분석에 활용되는 과정을 보여줍니다.

(주)골든플래닛

광고 문안 검토·대체어 추천

화장품 광고 문안의 단어별 위험도를 분석하고 대체 표현을 추천하는 모델.

담당
광고 데이터 수집 · OCR 처리 · 단어 분류 모델 개발

기술 / 방법
OCR · FastText · Bi-LSTM · NER

배경과 과제

화장품 광고 문안은 규제와 관련된 표현을 사전에 검토해야 합니다. 문안 전체의 적합 여부뿐 아니라 어떤 단어에 위험 가능성이 있는지 확인하고, 수정할 수 있는 대체 표현을 찾는 것이 필요했습니다. 심사 이전 단계에서 문안 검토를 보조하기 위한 단어 단위 분석과 추천 모델을 개발했습니다.

구현 구조

광고 수집과 OCR 텍스트 추출

일반 화장품 광고를 크롤링해 학습용 데이터를 수집했습니다. 광고 이미지에서 OCR로 문구를 추출해 자연어 모델이 처리할 수 있는 텍스트 데이터로 구성했습니다.

단어 단위 위험 표현 분류

FastText와 Bi-LSTM을 활용해 광고 문구의 단어를 분류하는 NER 모델을 개발했습니다. 문장 안에서 위험 가능성이 있는 표현을 단어 수준으로 확인할 수 있도록 모델링했습니다.

대체 표현 추천

법률 위반 가능성이 의심되는 단어에 대해 대체할 수 있는 표현을 추천하는 모델링을 수행했습니다. 위험 표현의 식별에서 수정 후보 제시까지 이어지는 검토 지원 흐름을 구성했습니다.

담당 업무

학습 데이터 수집·가공

모델 학습에 사용할 화장품 광고를 수집하고 OCR 기반 텍스트 추출을 수행했습니다. 이미지 형태의 광고 자료를 단어 분류와 추천 모델 개발에 활용할 수 있는 데이터로 전환했습니다.

NER 기반 단어 분류 모델 개발

FastText와 Bi-LSTM을 활용해 문장 내 단어를 분류하는 모델을 개발했습니다. 광고 문구의 위험 가능성을 표현 단위로 보여주기 위해 단어 수준의 분석을 적용했습니다.

추천 모델링과 검토 지원

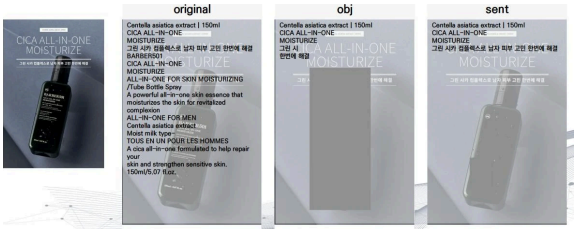
위반 가능성이 의심되는 표현에 대한 대체어 추천을 수행했습니다. 검토자가 문제 가능성이 있는 부분을 확인하고 문안을 수정하는 과정을 보조하는 용도로 모델을 구성했습니다.

결과와 기여

광고 이미지 수집부터 OCR 텍스트 추출, 단어 분류, 대체어 추천까지 연결하는 모델링을 수행했습니다. 광고 문안을 심사받기 전에 위험 표현과 수정 후보를 확인할 수 있도록 사전 검토를 지원했습니다.

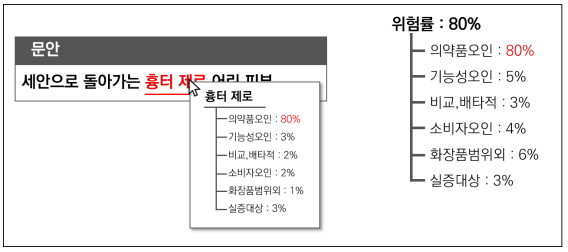
프로젝트 자료

광고 이미지의 OCR 처리 예시



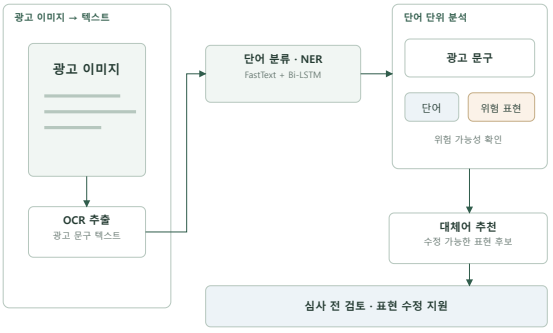
광고 이미지에서 추출한 텍스트와 분석 영역을 비교한 자료입니다. 이미지 속 문구를 단어 분류 모델의 입력으로 전환하는 과정을 보여줍니다.
기존 포트폴리오 · 9쪽

표현별 위험도 안내 예시



광고 문구의 특정 표현에 위험 유형과 점수를 표시하는 기존 포트폴리오의 예시 화면입니다. 단어별 분석 결과를 검토자에게 제시하는 방식을 보여줍니다.
기존 포트폴리오 · 9쪽

표현 단위 검토와 추천 구조



문장 전체의 판정이 아니라 단어 단위로 위험 표현을 찾고 대체 후보를 제시하는 프로젝트 특성을 반영했습니다.

(주)골든플래닛

앱 행동 기반 대출 이탈 예측

은행·카드 기업의 앱 행동 데이터를 활용한 대출 신청 및 이탈 예측 PoC.

담당
GA 데이터 통합 · 변수 추출 · 예측 모델 PoC

기술 / 방법
Google Analytics · XGBoost · Feature Engineering

배경과 과제

은행·카드 기업이 운영하는 세 개 앱에 축적된 GA 데이터에서 고객의 대출 신청과 이탈 행동을 설명하는 패턴을 찾는 과제였습니다. 서로 다른 앱의 행동 데이터를 통합하고 페이지별 행동을 예측 변수로 만드는 작업이 필요했습니다. PoC에서는 모델 성능 비교와 함께 테스트 데이터에서도 결과를 일반화할 수 있는지 검토하는 것이 중요했습니다.

구현 구조

세 개 앱의 GA 데이터 통합

고객사가 운영하는 세 개 앱의 GA 데이터를 통합했습니다. 앱과 페이지별로 축적된 고객 행동을 분석하고 신용대출 신청과 이탈 예측에 활용할 수 있는 데이터 기반을 마련했습니다.

행동 변수 추출과 모델 비교

페이지별 행동 패턴에서 유의한 변수를 추출하고 예측 모델을 개발했습니다. 여러 모델의 성능을 비교했으며, 실험에서는 XGBoost가 상대적으로 우수한 결과를 보였습니다.

일반화 검토와 수집 개선

테스트 데이터에 대한 일반화가 어렵다는 한계를 확인했습니다. 모델 비교 결과만으로 서비스 적용 가능성을 단정하지 않고, 과적합 문제 대응과 GA 수집기 개선을 함께 진행했습니다.

담당 업무

행동 데이터 분석과 변수 설계

GA 데이터 통합과 고객 행동 분석을 수행하고 페이지별 행동 정보를 예측 변수로 구성했습니다. 단순 방문 기록을 모델에 활용 가능한 Feature로 전환하는 작업을 담당했습니다.

예측 모델 PoC 수행

신용대출 신청·이탈 예측을 위한 모델링과 성능 비교를 수행했습니다. XGBoost 등 여러 모델의 실험 결과를 비교해 데이터에서 확인할 수 있는 예측 가능성을 검토했습니다.

과적합과 데이터 한계 검토

테스트 데이터에서 일반화가 어려운 점을 확인하고 모델의 한계를 분석했습니다. 과적합 대응과 GA 수집기 개선을 진행하며 모델 구조뿐 아니라 입력 데이터의 수집 방식까지 함께 검토했습니다.

결과와 기여

앱 행동 데이터를 통합하고 대출 신청·이탈 예측 PoC를 수행했습니다. XGBoost의 상대적인 성능 우위와 테스트 데이터 일반화의 한계를 함께 확인했으며, 운영 성능을 단정하는 대신 데이터 수집 개선과 후속 검증이 필요한 지점을 정리했습니다.

프로젝트 자료

BQML 모델링 과정 참고



기존 자료에 수록된 BQML 과정 이미지입니다. 데이터 수집·전처리에서 모델 생성·평가·예측으로 이어지는 단계를 설명합니다.
기존 포트폴리오 · 10쪽

AutoML Tables 과정 참고



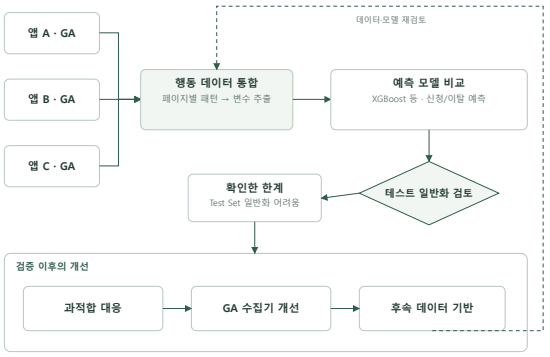
데이터 업로드, 학습, 모델 생성, 평가와 예측을 보여주는 AutoML Tables 참고 이미지입니다.
기존 포트폴리오 · 10쪽

Kubeflow 과정 참고



학습 정의, 파이프라인 설계, 실행, 점검과 배포를 보여주는 기존 자료의 Kubeflow 과정 이미지입니다. 세 이미지는 해당 프로젝트의 모델 성능 결과와 구분한 참고 자료입니다.
기존 포트폴리오 · 10쪽

일반화 검증과 데이터 개선의 순환



성능 수치를 임의로 시각화하지 않고, 여러 앱의 데이터 통합과 테스트 검증에서 확인한 한계·개선 흐름을 표현했습니다.

(주)골든플래닛

공공기관 SNS 운영 KPI

공공기관이 운영하는 약 200개 SNS 계정을 비교·평가하기 위한 지표 개발.

담당

SNS 운영 분석 · KPI 개발 · 제언 보고서 작성

기술 / 방법

Statistical Analysis · KPI Design · Reporting

배경과 과제

공공기관이 운영하는 약 200개 SNS 계정은 채널 특성과 운영 방식이 달라 같은 기준에서 효율을 판단하기 어려웠습니다. 계정별 현황을 비교하고 유지·폐쇄를 검토하려면 채널의 차이를 고려한 평가 지표와 분석 근거가 필요했습니다. 운영 현황 분석을 종합 KPI와 계정별 제언 보고서로 연결하는 컨설팅 프로젝트였습니다.

구현 구조

계정 운영 현황과 채널 특성 분석

다양한 SNS 채널에 속한 약 200개 계정의 운영 현황을 통계적으로 분석했습니다. 채널마다 다른 특성과 계정별 운영 상태를 파악해 비교·평가의 기반으로 삼았습니다.

종합 KPI 개발과 효율 평가

계정의 운영 효율을 비교할 수 있도록 종합적인 KPI를 개발했습니다. 채널 특성을 고려하면서도 기관이 전체 계정을 같은 선상에서 검토할 수 있는 평가 기준을 구성했습니다.

계정별 제언 보고서 작성

계정별 분석 결과와 인사이트를 정리하고 유지·폐쇄 검토를 지원하는 보고서를 작성했습니다. 평가 결과를 실제 디지털 자산 운영에 활용할 수 있는 제언으로 연결했습니다.

담당 업무

통계적 운영 현황 분석

SNS 채널별 특성과 계정 운영 현황을 통계적으로 분석했습니다. 개별 계정의 상태를 파악하는 동시에 기관 전체의 디지털 자산을 비교할 수 있도록 분석 결과를 정리했습니다.

평가 지표 설계

운영 효율을 판단하기 위한 종합 KPI를 개발했습니다. 다양한 채널에 속한 계정의 효능성을 비교할 수 있도록 평가 기준을 구성하고 분석에 적용했습니다.

인사이트와 운영 제언

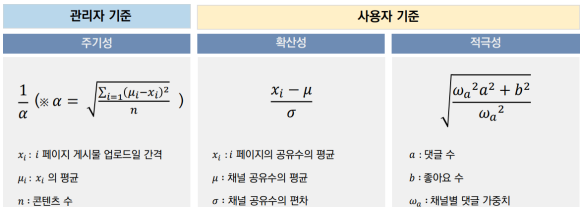
계정별 분석을 바탕으로 인사이트 제언 보고서를 작성했습니다. 단순 순위 제시에 그치지 않고 계정 유지와 폐쇄 등 운영 판단을 지원하는 자료로 결과를 전달했습니다.

결과와 기여

약 200개 SNS 계정을 대상으로 운영 효율을 평가할 수 있는 KPI와 계정별 제언 보고서를 제공했습니다. 통계 분석을 기관의 디지털 자산 관리와 운영 전략 검토에 연결하는 업무를 수행했습니다.

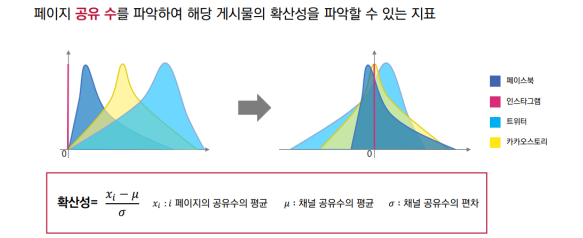
프로젝트 자료

관리자·사용자 관점의 KPI 정의



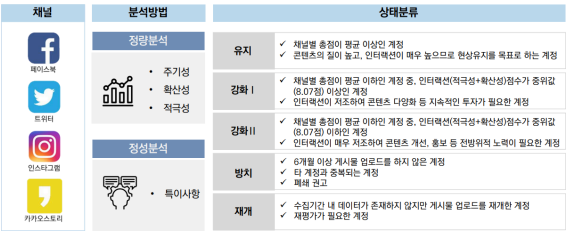
관리자 관점의 주기성과 사용자 관점의 확산성·적극성을 구분한 지표 정의입니다. 업로드 간격, 공유 수, 댓글·좋아요를 평가 기준에 반영합니다.
기존 포트폴리오 · 11쪽

채널 간 확산성 비교



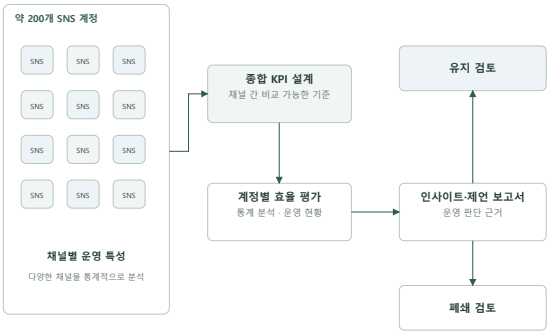
채널별 공유 수의 평균과 표준편차를 이용해 확산성을 비교하는 방식입니다. 서로 다른 SNS 채널의 분포 차이를 고려한 지표 구성 과정을 보여줍니다.
기존 포트폴리오 · 11쪽

계정 상태 분류와 운영 제언



정량·정성 분석을 결합해 유지, 강화, 방치, 재개 등 계정 상태를 구분한 원본 기준입니다. 평가 결과가 운영과 폐쇄 검토에 어떻게 연결되는지 보여줍니다.
기존 포트폴리오 · 11쪽

계정군 비교와 운영 의사결정



계정 묶음, KPI 평가, 제언 보고서와 유지·폐쇄 검토를 분리해 통계 분석 프로젝트의 결과 사용 방식을 드러냈습니다.

수상내역

한국거래소

KRX 주식투자 알고리즘 경진대회

제2회 KRX 주식투자 알고리즘 경진대회 최우수상, 1위.

담당

주가 예측 모델링 · 매매 알고리즘 구축

기술 / 방법

SCINet · Time Series Forecasting · Blocked Cross Validation

배경과 과제

과거 주가에서 미래 수익률을 예측하는 모델을 만들고, 예측 결과를 실제 종목 선정과 매매 규칙으로 연결하는 과제였습니다. 시계열의 순서와 최신 정보의 반영, 종목별 변동성을 함께 고려해야 했습니다. 예측값만으로 종목을 선택하기보다 과거 변동성과 미래 수익률 예측을 결합한 전략을 구성했습니다.

구현 구조

종목 구성과 입력 데이터

금융 업종을 그룹화하고 이상치와 변동성을 고려해 52개 종목을 선별했습니다. 과거 32일의 주가 데이터를 입력으로 사용해 3일 후의 수익률을 예측하는 시계열 문제로 구성했습니다.

SCINet 학습과 검증 방식 조정

SCINet을 커스터마이징해 수익률 예측 모델을 학습했습니다. Blocked Cross Validation을 조정해 최신 정보의 가중치를 높이고, 입력과 추론 값의 차이를 줄이는 방법을 적용했습니다.

점수 기반 종목 선정과 매매

과거 주가 변동성과 미래 예측값을 점수화해 상승 가능성이 높은 종목을 선정했습니다. 선정한 종목을 매수하고 3일 뒤 매도하는 운용 전략으로 예측과 매매를 연결했습니다.

담당 업무

시계열 예측 모델링

과거 32일과 3일 후 수익률의 관계를 학습하도록 SCINet을 커스터마이징했습니다. 종목 구성부터 입력 데이터와 예측 목표를 정의하고 시계열 모델 학습을 수행했습니다.

최신 정보를 반영한 검증

시계열 특성에 맞춰 Blocked Cross Validation을 조정했습니다. 최신 정보에 더 높은 가중치를 주고 입력과 추론 값의 차이를 줄이는 방식으로 예측 과정을 개선했습니다.

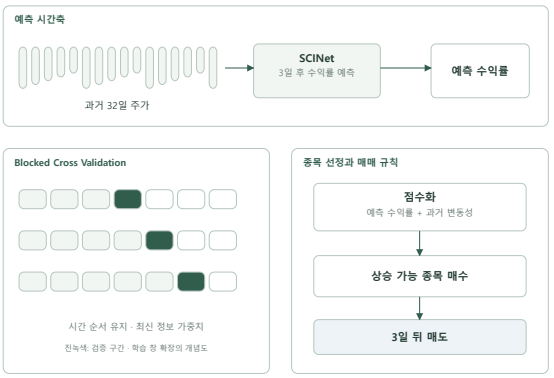
매매 알고리즘 구축

예측 수익률과 과거 주가 변동성을 함께 점수화하는 종목 선정 로직을 구성했습니다. 매수 후 3일 뒤 매도하는 규칙으로 모델의 예측 결과를 운용 전략에 반영했습니다.

결과와 기여

2023년 11월 23일 한국거래소가 주최한 제2회 KRX 주식투자 알고리즘 경진대회에서 최우수상(1위)을 수상했습니다. 시계열 예측 모델의 학습·검증과 종목 선정·매매 규칙을 함께 구성하며 예측 모델을 운용 로직으로 연결했습니다.

예측·검증·운용의 세 관점



첨부 자료의 32일 입력과 3일 예측, 검증 방식 조정, 변동성을 반영한 종목 선정·매매 규칙을 구분했습니다.

Gzip 압축기술과 K-NN 알고리즘을 사용한 준지도학습 한국어 문장 분류 방법

원문을 변형하지 않고, 압축 기반 유사도로 비레이블 데이터를 학습에 활용하는 한국어 문장 분류 연구.

신호영 · 한양대학교 인공지능융합대학원 인공지능시스템학과

연구 주제	핵심 방법	실험 범위
저자원 한국어 문장 분류	Gzip · K-NN · Pseudo Label	3개 데이터셋 · 8개 모델

석사학위논문 · 2026.08

연구 질문

레이블 구축 비용이 높은 환경에서, 소량의 정답 데이터와 레이블이 없는 문장을 함께 활용할 수 있을까? 자연어 데이터에 단어 교체나 노이즈를 넣으면 문장 의미가 바뀔 수 있다는 점에서 출발했습니다.

본 연구는 문장을 직접 변형하는 대신 Gzip 압축 길이로 문장 간 유사도를 계산하고, 가까운 참조 문장의 클래스 분포를 학습의 보조 신호로 사용합니다. 기존 Gzip K-NN 방식이 클래스를 직접 결정하는 데 가깝다면, 이 연구에서는 확률적 의사 레이블을 생성하는 모듈로 활용합니다.

핵심 비교 대상은 같은 소량의 레이블 데이터만으로 학습한 Baseline입니다. 다른 준지도학습 기법 전체의 우열이나 BERT와 LLM의 절대 성능 우열보다, 동일한 학습 절차가 각 모델·과제에 어떤 영향을 주는지 살폈습니다.

제안 방법

1. 레이블·비레이블 데이터의 공동 학습

한 배치에 레이블 데이터와 비레이블 데이터를 함께 넣습니다. 실제 정답이 있는 문장은 정답과 모델 출력의 손실을 계산하고, 비레이블 문장은 Gzip K-NN이 만든 확률 분포와 모델 출력의 손실을 계산합니다.

2. 압축 거리와 K-NN 기반 의사 레이블

비레이블 문장 x와 참조 문장 r을 각각 압축한 길이 C(x), C(r), 두 문장을 이어 붙여 압축한 길이 C(xr)를 구합니다. 다음의 정규화 압축 거리 NCD로 참조 문장을 정렬하고, 가까운 K개 이웃의 클래스 빈도를 확률 분포로 변환합니다.

$$\mathrm{NCD}(x,\ r)\ =\ \frac{C(xr)\ -\ \min\{C(x),\ C(r)\}}{\max\{C(x),\ C(r)\}}$$

예를 들어 25개 이웃의 클래스 빈도가 3·17·5이면 의사 레이블은 [0.12, 0.68, 0.20]입니다. 가장 많은 클래스 하나만 선택하는 하드 레이블이 아니라 이웃 분포를 학습에 전달합니다.

3. 손실 결합과 가중치 제어

$$L\ =\ L_{\ \mathrm{real}}\ +\ W(\mathrm{epoch})\ \times\ L_{\ \mathrm{pseudo}}$$

의사 레이블 손실의 반영 방식을 두 가지로 비교했습니다. 감소 스케줄은 초기 가중치 0.8에서 지수적으로 줄인 뒤 zero_weight 시점부터 0으로 만듭니다. 고정 설정 W=1은 학습 전 구간에서 같은 비중으로 의사 레이블 손실을 반영합니다.

감소 스케줄은 초기 보조 신호를 활용한 뒤 실제 레이블 중심으로 학습하도록 하는 전략입니다. 이것이 모든 모델에 유리하다고 가정하지 않고, 고정 설정과 함께 비교했습니다.

실험 설계

저자원 데이터 구성

각 클래스에서 정답이 있는 문장 5개를 추출하고, 학습 데이터에서 레이블을 사용하지 않는 문장 250개를 별도로 구성했습니다. 검증은 정답이 있는 데이터로 수행했습니다. K-MHaS는 원래 멀티레이블 구조를 포함하지만, 이 실험에서는 단일 레이블이 부여된 샘플만 사용했습니다.

논문 표 4-1 · 데이터 구성

데이터셋	분류 과제	클래스	레이블 학습	비레이블 학습	검증
KLUE-YNAT	뉴스 제목 주제	7	35	250	9,107
NSMC	영화 리뷰 감성	2	10	250	50,000
K-MHaS	혐오 표현 분류	9	45	250	19,185

두 종류의 모델군

BERT 계열 · 분류 출력	LLM 계열 · 클래스 라벨 생성
klue/roberta-small · base · large	Gemma 3 · 270M / 1B
kykim/bert-kor-base	Qwen3 · 0.6B / 1.7B

BERT 계열은 문장에서 분류 출력을 만들고, LLM은 클래스 라벨을 텍스트로 생성합니다. 출력 형식은 다르지만 실제 레이블 손실과 의사 레이블 손실을 결합하는 비교 구조는 유지했습니다.

논문 표 5-1 및 실험 환경

항목	논문에 기재된 공통 설정
클래스별 레이블	5개
비레이블 샘플	데이터셋별 250개
K-NN의 K	25
학습률	1e-5
학습 횟수	50 epoch
초기 의사 레이블 가중치	0.8
zero_weight 후보	3, 5, 10, 15, 20, 25, 30
비교 설정	Baseline / 감소 스케줄 / W=1 고정
실험 GPU	NVIDIA A100

주요 결과

검증 Macro-F1을 기준으로 일부 설정에서 Baseline보다 높은 값이 관찰됐습니다. 다만 데이터셋과 모델에 따라 최적의 의사 레이블 반영 방식이 달랐고, 학습 후반의 손실 증가나 성능 변동도 함께 나타났습니다.

논문 표 5-5-9에서 발췌한 검증 Macro-F1 예시

데이터셋 · 모델	Baseline	비교 최고값	설정	F1 차이
KLUE-YNAT · RoBERTa-large	0.614	0.646	z_w=3	+0.032
KLUE-YNAT · Gemma 3 1B	0.165	0.255	W=1	+0.090
NSMC · RoBERTa-large	0.631	0.669	z_w=5	+0.038
NSMC · Qwen3 1.7B	0.602	0.664	z_w=3	+0.062
K-MHaS · RoBERTa-large	0.316	0.349	z_w=5	+0.033
K-MHaS · Gemma 3 270M	0.074	0.090	W=1	+0.016

F1 차이는 비율 증가가 아닌 점수의 절대 차이입니다. 비교 최고값은 논문에 정리된 모델·데이터셋별 설정 중의 값이며, 서로 다른 모델의 절대 우열을 뜻하지 않습니다. z_w는 의사 레이블 손실을 제거하는 epoch입니다.

BERT 계열: 감소 스케줄의 효과

결과 요약 표에서는 BERT 계열 12개 모델·데이터셋 조합 중 11개에서 감소 스케줄의 최고값이 W=1 고정보다 높았습니다. 예외는 NSMC의 RoBERTa-small로, W=1이 0.627, 감소 스케줄 최고값이 0.626입니다. 보조 신호를 계속 유지하는 것보다 학습 후반에 줄이는 방식이 상대적으로 유리한 조건이 많았습니다.

LLM 계열: 모델·데이터셋별로 다른 최적 설정

KLUE-YNAT의 Gemma 3 1B·270M과 Qwen3 1.7B, K-MHaS의 Gemma 3 270M은 W=1 설정이 더 높았습니다. 반면 표 5-9의 다른 조합에서는 감소 스케줄의 최고값이 더 높아, 생성형 분류에서도 고정 가중치가 일관되게 우수하다고 해석하지 않았습니다.

학습 손실과 F1을 함께 보기

F1이 개선된 설정에서도 검증 손실이 증가하거나 성능 변동이 나타날 수 있었습니다. 특히 NSMC처럼 짧은 부정 표현과 미세한 문맥 차이가 감성을 바꾸는 과제에서는 압축 유사도로 생성한 의사 레이블이 잡음이 될 수 있습니다.

▼ **BERT 계열 전체 결과표 · 표 5-5**

▼ **LLM 기반 전체 결과표 · 표 5-9**

한계와 후속 과제

압축 유사도와 의미 유사도의 차이

Gzip은 반복되는 문자·표현과 구조적 패턴을 활용합니다. 따라서 표현이 비슷하지만 의미가 반대인 문장을 가깝게 판단하거나, 같은 뜻의 다른 표현을 멀게 판단할 수 있습니다. 원문을 변형하지 않는 장점과 별개로, 의사 레이블의 신뢰도는 과제의 언어적 특성에 영향을 받습니다.

고정된 데이터 규모와 하이퍼파라미터

클래스별 레이블 5개, 비레이블 250개, K=25를 고정한 실험입니다. 레이블·비레이블 규모와 K 변화에 따른 민감도 분석이나 다양한 준지도학습 기법과의 포괄적 비교는 연구 범위에 포함하지 않았습니다.

다음 검증 방향

- 의사 레이블의 신뢰도 추정과 선택 기준
- 모델 구조별 의사 레이블 손실 반영 전략
- 가중치 함수와 zero_weight 설정의 체계적 비교
- 비레이블 데이터 규모·구성 변화와 반복 실험의 안정성 검토

이 연구는 모든 분류 과제의 성능을 높이는 일반 해법보다, 원문 변형 없이 비레이블 데이터를 활용하는 보조적 학습 절차의 가능성과 한계를 정리한 작업입니다.

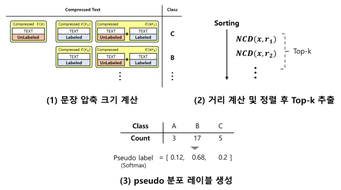
그림·표 출처: 신호영, 「Gzip 압축기술과 K-NN 알고리즘을 사용한 준지도학습 한국어 문장 분류 방법」, 한양대학교 인공지능융합대학원 석사학위논문, 2026.08. 원본 그림과 표 페이지를 수록했습니다. 원문 이용허락: 저작자표시-비영리-변경금지 2.0 대한민국(CC BY-NC-ND 2.0 KR).

그림 3-1 · 레이블·비레이블 데이터의 공동 학습



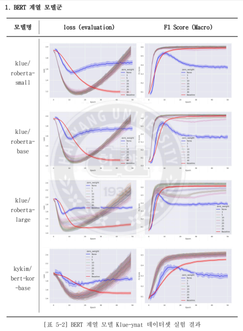
실제 레이블 손실과 Gzip K-NN으로 만든 의사 레이블 손실을 같은 학습 과정에서 결합하는 원본 구조입니다.
신호영, 석사학위논문, 2026 · 본문 9쪽

그림 3-3 · 확률적 의사 레이블 생성



문장별 압축 길이로 NCD를 구하고 가까운 K개 참조 문장을 선택합니다. 이웃의 클래스 분포를 정규화해 확률적 레이블을 구성합니다.
신호영, 석사학위논문, 2026 · 본문 11쪽

표 5-2 · KLUE-YNAT 학습 곡선

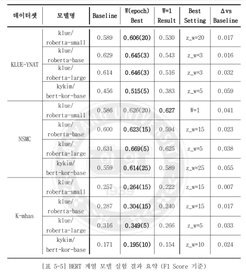


[표 5-2] BERT 계열 모델 klue-ynat 데이터셋 실험 결과

25

BERT 계열의 검증 손실과 Macro-F1 변화를 함께 제시한 원본 페이지입니다. 손실과 분류 지표의 변화가 항상 같은 방향은 아니라는 점을 확인할 수 있습니다.
신호영, 석사학위논문, 2026 · 본문 25쪽

표 5-5 · BERT 계열 결과 요약



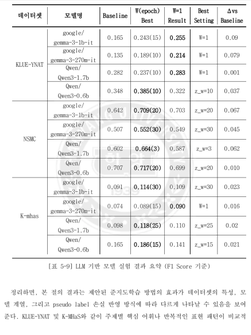
데이터셋	모델명	Baseline	W(epoch) Best	W=1 Result	Best Setting	Δvs Baseline
KLUE-YNAT	klue/roberta-small	0.589	**0.606(20)**	0.530	z_w=20	0.017
	klue/roberta-base	0.629	**0.646(3)**	0.543	z_w=3	0.016
	klue/roberta-large	0.614	**0.646(3)**	0.516	z_w=3	0.032
	kykim/bert-kor-base	0.456	**0.515(5)**	0.383	z_w=5	0.059
NSMC	klue/roberta-small	0.586	0.626(20)	**0.627**	W=1	0.041
	klue/roberta-base	0.600	**0.625(15)**	0.594	z_w=15	0.025
	klue/roberta-large	0.631	**0.669(5)**	0.625	z_w=5	0.038
	kykim/bert-kor-base	0.559	**0.614(25)**	0.589	z_w=25	0.055
K-mhas	klue/roberta-small	0.257	**0.264(15)**	0.222	z_w=15	0.007
	klue/roberta-base	0.287	**0.304(15)**	0.240	z_w=15	0.017
	klue/roberta-large	0.316	**0.349(5)**	0.316	z_w=5	0.033
	kykim/bert-kor-base	0.171	**0.195(10)**	0.154	z_w=10	0.024

[표 5-5] BERT 계열 모델 실험 결과 요약 (F1 Score 기준)

30

데이터셋별 Baseline, 감소 스케줄의 최고값, W=1 고정 결과와 최고 설정을 비교한 원본 표입니다.
신호영, 석사학위논문, 2026 · 본문 30쪽

표 5-9 · LLM 기반 결과 요약



데이터셋	모델명	Baseline	W(epoch) Best	W=1 Result	Best Setting	Δvs Baseline
KLUE-YNAT	google/gemma-3-1b-it	0.165	0.243(15)	**0.255**	W=1	0.09
	google/gemma-3-270m-it	0.135	0.189(10)	**0.214**	W=1	0.079
	Qwen/Qwen3-1.7b	0.282	0.237(10)	**0.283**	W=1	0.001
	Qwen/Qwen3-0.6b	0.348	**0.385(10)**	0.322	z_w=10	0.037
NSMC	google/gemma-3-1b-it	0.642	**0.709(20)**	0.703	z_w=20	0.067
	google/gemma-3-270m-it	0.507	**0.552(30)**	0.549	z_w=30	0.045
	Qwen/Qwen3-1.7b	0.602	**0.664(3)**	0.587	z_w=3	0.062
	Qwen/Qwen3-0.6b	0.707	**0.717(20)**	0.699	z_w=20	0.010
K-mhas	google/gemma-3-1b-it	0.091	**0.114(30)**	0.109	z_w=30	0.023
	google/gemma-3-270m-it	0.074	0.086(15)	**0.090**	W=1	0.016
	Qwen/Qwen3-1.7b	0.098	**0.118(25)**	0.110	z_w=25	0.02
	Qwen/Qwen3-0.6b	0.165	**0.186(15)**	0.141	z_w=15	0.021

[표 5-9] LLM 기반 모델 실험 결과 요약 (F1 Score 기준)

정리하면, 본 절의 결과는 제안된 준지도학습 방법의 효과가 데이터셋의 특성, 모델 계열, 그리고 pseudo label 손실 반영 방식에 따라 다르게 나타날 수 있음을 보여준다. KLUE-YNAT 및 K-MHaS와 같이 주제별 혹은 어휘나 반복적인 표현 패턴이 비교적

36

Gemma와 Qwen의 생성형 분류 실험 결과입니다. W=1의 이점과 감소 스케줄의 이점이 모델·데이터셋에 따라 달라지는 것을 함께 볼 수 있습니다.
신호영, 석사학위논문, 2026 · 본문 36쪽

그림 3-2 · 압축 유사도가 포착하는 것과 놓치는 것



핵심 표현이 반복되는 문장은 가깝게 판단할 수 있지만, 동의어나 부정어처럼 의미에 중요한 차이는 압축 거리와 일치하지 않을 수 있습니다.
신호영, 석사학위논문, 2026 · 본문 9쪽